

Telco Churn Classification

Data Source:

<https://www.kaggle.com/datasets/blastchar/telco-customer-churn>

Team:

1. Alya Rahma Rahadian
-


Simple Exploratory Data Analysis

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7043 entries, 0 to 7042
Data columns (total 21 columns):
#   Column                Non-Null Count  Dtype
---  -
0   customerID            7043 non-null   object
1   gender                 7043 non-null   object
2   SeniorCitizen          7043 non-null   int64
3   Partner                7043 non-null   object
4   Dependents             7043 non-null   object
5   tenure                 7043 non-null   int64
6   PhoneService           7043 non-null   object
7   MultipleLines           7043 non-null   object
8   InternetService        7043 non-null   object
9   OnlineSecurity          7043 non-null   object
10  OnlineBackup            7043 non-null   object
11  DeviceProtection        7043 non-null   object
12  TechSupport             7043 non-null   object
13  StreamingTV             7043 non-null   object
14  StreamingMovies         7043 non-null   object
15  Contract                7043 non-null   object
16  PaperlessBilling        7043 non-null   object
17  PaymentMethod           7043 non-null   object
18  MonthlyCharges          7043 non-null   float64
19  TotalCharges            7043 non-null   object
20  Churn                   7043 non-null   object
dtypes: float64(1), int64(2), object(18)
memory usage: 1.1+ MB
```

Dataset terdiri dari 7.043 observasi (pelanggan) dan 21 kolom, dengan churn sebagai variabel target, 3 prediktor numerik, dan sisanya prediktor kategorik. Proporsi variabel kategorik jauh lebih banyak dibanding numerik.

	SeniorCitizen	tenure	MonthlyCharges
count	7043.000000	7043.000000	7043.000000
mean	0.162147	32.371149	64.761692
std	0.368612	24.559481	30.090047
min	0.000000	0.000000	18.250000
25%	0.000000	9.000000	35.500000
50%	0.000000	29.000000	70.350000
75%	0.000000	55.000000	89.850000
max	1.000000	72.000000	118.750000


Dari statistika deskriptif data numerik ditemukan bahwa Mean Tenure sekitar 32 bulan dengan rentang sangat lebar (0–72 bulan). Sedangkan MonthlyCharges memiliki rata-rata sekitar 65 dan menunjukkan standar deviasi sebesar 30. Senior Citizen memiliki pola yang cukup aneh pada kuartil, dimana dari 0 hingga 75%, nilainya adalah 0.



Dari visualisasi histogram dan boxplot, didapat bahwa data seniorcitizen memiliki pola yang terpusat hanya di 0 dan 1, ini adalah indikasi bahwa data sebetulnya merupakan tipe data boolean ataupun kategorik dibandingkan numerik. Sedangkan untuk kedua data numerik lainnya tidak memiliki outlier.


	gender	SeniorC itizen	Partner	Depend ents	PhoneS ervice	Multiple Lines	Internet Service	OnlineS ecurity	OnlineB ackup	Device Protecti	TechSu pport	Streami ngTV	Streami ngMovi	Contrac t	Paperle ssBillin	Payme ntMeth	Churn
count	7032	7032	7032	7032	7032	7032	7032	7032	7032	7032	7032	7032	7032	7032	7032	7032	7032
unique	2	2	2	2	2	3	3	3	3	3	3	3	3	3	2	4	2
top	Male	0	No	No	Yes	No	Fiber optic	No	No	No	No	No	No	Month- to- month	Yes	Electron ic check	No
freq	3549	5890	3639	4933	6352	3385	3096	3497	3087	3094	3472	2809	2781	3875	4168	2365	5163

Terdapat banyak data kategorik dengan 2-4 varian. Churn memiliki proporsi terbanyak No sebanyak 5163 dari 7032 baris data.




Customer ID dan Total Charges yang dilabel sebagai data object menunjukkan ketidakcocokan sehingga menghasilkan plot yang kurang efisien, dan lebih baik diubah menjadi variabel numerik. Untuk pengguna cukup balance dari segi gender dengan lelaki sedikit lebih banyak, memiliki langgan streaming film (dengan pengecualian orang yang tidak memiliki akses internet), dan partner dengan sedikit lebih banyak orang yang tidak berpasangan. Sedangkan lebih banyak orang yang bukan Dependents, memiliki phone service, tidak memiliki online security, kontrak dari bulan ke bulan, memilih Paperless Billing, membayar dengan check elektronik, juga tidak Churn.


Berikut adalah visualisasi sesudah tipe data disesuaikan:



Tidak terdapat outlier pada data numerik manapun, dengan total charges positively skewed sedangkan tenure menunjukkan sedikit indikasi 2 punuk dalam distribusi.



Untuk penambahan, Senior Citizen didominasi oleh non-senior, sedangkan hanya sedikit sekali senior pada row data ini.



Hubungan kuat antara tenure dan TotalCharges sebesar 0.83. Tidak ditemukan korelasi numerik ekstrem yang mengindikasikan multikolinearitas berbahaya untuk sebagian besar model.

Data Preprocessing

```
In [18]: df.shape
Out[18]: (7043, 20)

In [19]: df.duplicated().sum()
Out[19]: 22

In [20]: df.drop_duplicates(inplace=True)
df.shape
Out[20]: (7021, 20)

In [21]: df.isnull().values.any()
Out[21]: True

In [22]: df = df.dropna()

In [23]: df.isnull().values.any()
Out[23]: False

In [24]: df.shape
Out[24]: (7010, 20)
```

Berdasarkan hasil eksplorasi awal, dataset awal terdiri dari 7.043 baris dan 20 kolom. Pemeriksaan terhadap data duplikat menunjukkan terdapat 22 baris duplikat, yang mengindikasikan adanya pengulangan data pelanggan. Selain itu, pengecekan nilai kosong (missing values) menunjukkan bahwa dataset mengandung nilai null, dan data ini dipilih untuk dihapus karena jumlah yang sedikit. Sehingga terdapat 7021 baris.

Langkah pembersihan dilakukan dengan menghapus baris yang memiliki nilai kosong. Setelah proses ini, jumlah observasi berkurang menjadi 7.010 baris dengan 20 kolom, dan pengecekan ulang memastikan bahwa tidak terdapat missing values yang tersisa dalam dataset. Penghapusan ini relatif aman karena jumlah data yang dihapus sangat kecil dibandingkan total data, sehingga tidak mengubah distribusi data secara signifikan.

```
(z_scores > 3).sum(axis=0)
outliers_before = (z_scores > 3).sum()
outliers_before

tenure      0
MonthlyCharges  0
TotalCharges  0
dtype: int64
```

Selanjutnya, dilakukan deteksi outlier pada variabel numerik, yaitu tenure, MonthlyCharges, dan TotalCharges, menggunakan metode Z-score dengan ambang batas $|z| > 3$. Hasil perhitungan menunjukkan bahwa tidak terdapat outlier pada ketiga variabel numerik tersebut. Hal ini mengindikasikan bahwa distribusi data numerik masih berada dalam rentang yang wajar dan tidak mengandung nilai ekstrem yang berpotensi mendistorsi proses pelatihan model.

Secara keseluruhan, setelah tahap data cleaning dan validasi ini, dataset berada dalam kondisi bersih, konsisten, dan siap digunakan

Uji Statistik

Dilakukan uji statistik untuk mencari tahu hubungan antar variabel kategorik, juga hubungan seluruh variabel dengan variabel Target.

	var1	var2	p_value	decision	interpretation
122	OnlineSecurity	StreamingTV	0.000000	Tolak H0	Ada hubungan signifikan
123	OnlineSecurity	StreamingMovies	0.000000	Tolak H0	Ada hubungan signifikan
68	PhoneService	MultipleLines	0.000000	Tolak H0	Ada hubungan signifikan
121	OnlineSecurity	TechSupport	0.000000	Tolak H0	Ada hubungan signifikan
120	OnlineSecurity	DeviceProtection	0.000000	Tolak H0	Ada hubungan signifikan
...	...	...	...	...	...
8	gender	DeviceProtection	0.920123	Gagal tolak H0	Tidak ada hubungan signifikan
76	PhoneService	Contract	0.920687	Gagal tolak H0	Tidak ada hubungan signifikan
1	gender	Partner	0.926875	Gagal tolak H0	Tidak ada hubungan signifikan
51	Dependents	PhoneService	0.963076	Gagal tolak H0	Tidak ada hubungan signifikan
37	Partner	InternetService	0.994281	Gagal tolak H0	Tidak ada hubungan signifikan

136 rows × 5 columns

Dari uji chi-square diatas dapat dilihat bahwa beberapa variabel memiliki hubungan signifikan, akan tetapi kekuatan dari hubungan itu belum bisa diketahui, oleh karena itu dilanjut dengan uji Cramer's V sebagai berikut:

	var1	var2	cramers_v	strength
58	PhoneService	MultipleLines	1.000000	Kuat
121	StreamingTV	StreamingMovies	0.771206	Kuat
110	DeviceProtection	StreamingMovies	0.736151	Kuat
109	DeviceProtection	StreamingTV	0.733526	Kuat
93	OnlineSecurity	TechSupport	0.733034	Kuat
108	DeviceProtection	TechSupport	0.726461	Kuat
81	InternetService	OnlineSecurity	0.724367	Kuat
84	InternetService	TechSupport	0.722809	Kuat
101	OnlineBackup	TechSupport	0.719807	Kuat
100	OnlineBackup	DeviceProtection	0.719108	Kuat
91	OnlineSecurity	OnlineBackup	0.718407	Kuat
92	OnlineSecurity	DeviceProtection	0.717263	Kuat
85	InternetService	StreamingTV	0.717195	Kuat
116	TechSupport	StreamingMovies	0.716470	Kuat
115	TechSupport	StreamingTV	0.716248	Kuat
86	InternetService	StreamingMovies	0.715959	Kuat
102	OnlineBackup	StreamingTV	0.714687	Kuat
103	OnlineBackup	StreamingMovies	0.713718	Kuat
95	OnlineSecurity	StreamingMovies	0.708224	Kuat
94	OnlineSecurity	StreamingTV	0.707779	Kuat
82	InternetService	OnlineBackup	0.707177	Kuat
83	InternetService	DeviceProtection	0.707107	Kuat

Data di atas menunjukkan variabel dengan kategori hubungan yang kuat. Phone Service dan Multiple Line menunjukkan nilai yang hampir sempurna, sehingga bisa menjadi indikasi Multikolinearitas yang besar, oleh karena itu apabila terdapat kendala pada model, dapat dilakukan feature selection.

Sedangkan untuk hubungan prediktor kategorik dengan target adalah sebagaimana tertulis pada tabel di bawah ini:

	feature	cramers_v	strength
132	Contract	0.409560	Sedang-kuat
99	OnlineSecurity	0.346992	Sedang-kuat
120	TechSupport	0.342506	Sedang-kuat
90	InternetService	0.321909	Sedang-kuat
135	PaymentMethod	0.302960	Sedang-kuat
107	OnlineBackup	0.291902	Lemah-sedang
114	DeviceProtection	0.281159	Lemah-sedang
129	StreamingMovies	0.230702	Lemah-sedang
125	StreamingTV	0.230143	Lemah-sedang
134	PaperlessBilling	0.191127	Lemah-sedang
57	Dependents	0.162777	Lemah-sedang
30	SeniorCitizen	0.150105	Lemah-sedang
44	Partner	0.149660	Lemah-sedang
80	MultipleLines	0.040036	Sangat lemah
69	PhoneService	0.011147	Sangat lemah
15	gender	0.008223	Sangat lemah

Contact, Online Security, Internet Service, dan Payment Method memiliki hubungan dengan asosiasi Sedang-Kuat dibandingkan variabel-variabel lain dengan asosiasi yang lebih lemah. Selanjutnya dilakukan Uji-T untuk mengetahui hubungan antara prediktor numerik dengan target.

```
In [51]: from scipy.stats import ttest_ind

group1 = df[df["Churn"] == "No"]["tenure"]
group2 = df[df["Churn"] == "Yes"]["tenure"]

t_stat, p_value = ttest_ind(group1, group2, equal_var=False)
t_stat, p_value

Out[51]: (34.97187009750348, 2.3470747188949523e-234)

In [52]: group1 = df[df["Churn"] == "No"]["MonthlyCharges"]
group2 = df[df["Churn"] == "Yes"]["MonthlyCharges"]

t_stat, p_value = ttest_ind(group1, group2, equal_var=False)
t_stat, p_value

Out[52]: (-18.34091879095257, 2.6573571445160277e-72)

In [53]: group1 = df[df["Churn"] == "No"]["TotalCharges"]
group2 = df[df["Churn"] == "Yes"]["TotalCharges"]

t_stat, p_value = ttest_ind(group1, group2, equal_var=False)
t_stat, p_value

Out[53]: (18.80076821738761, 1.1524944112838114e-75)
```

Didapat bahwa pada seluruh variabel $T_{stat} > T_{tabel}$ dan $P_{value} < \alpha(0.05)$ sehingga dapat disimpulkan bahwa Tolak H_0 atau seluruh variabel signifikan.

Feature Engineering

Dilakukan Label Encoding terlebih dahulu pada variabel binary di salinan df yakni df_fe sehingga jadi sebagai berikut.

	gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService	MultipleLines	InternetService	OnlineSecurity	OnlineBackup	DeviceProtection	TechS
0	0	0	1	0	1	0	No phone service	DSL	No	Yes	No	
1	1	0	0	0	34	1	No	DSL	Yes	No	Yes	
2	1	0	0	0	2	1	No	DSL	Yes	Yes	No	
3	1	0	0	0	45	0	No phone service	DSL	Yes	No	Yes	
4	0	0	0	0	2	1	No	Fiber optic	No	No	No	

Selanjutnya dilakukan one-hot encoding pada seluruh variabel kategorik dengan 3 atau lebih kategori sehingga df_fe sebagai berikut:

	gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService	PaperlessBilling	MonthlyCharges	TotalCharges	Churn	...	TechSupport_Yes	Stream interr
0	0	0	1	0	1	0	1	29.85	29.85	0	...	0	
1	1	0	0	0	34	1	0	56.95	1889.50	0	...	0	
2	1	0	0	0	2	1	1	53.85	108.15	1	...	0	
3	1	0	0	0	45	0	0	42.30	1840.75	0	...	1	
4	0	0	0	0	2	1	1	70.70	151.65	1	...	0	

5 rows × 31 columns

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 7010 entries, 0 to 7042
Data columns (total 31 columns):
#   Column                                     Non-Null Count  Dtype
---  -
0   gender                                     7010 non-null   int64
1   SeniorCitizen                             7010 non-null   object
2   Partner                                    7010 non-null   int64
3   Dependents                                7010 non-null   int64
4   tenure                                     7010 non-null   int64
5   PhoneService                              7010 non-null   int64
6   PaperlessBilling                          7010 non-null   int64
7   MonthlyCharges                           7010 non-null   float64
8   TotalCharges                             7010 non-null   float64
9   Churn                                     7010 non-null   int64
10  MultipleLines_No phone service            7010 non-null   uint8
11  MultipleLines_Yes                         7010 non-null   uint8
12  InternetService_Fiber optic              7010 non-null   uint8
13  InternetService_No                        7010 non-null   uint8
14  OnlineSecurity_No internet service        7010 non-null   uint8
15  OnlineSecurity_Yes                       7010 non-null   uint8
16  OnlineBackup_No internet service          7010 non-null   uint8
17  OnlineBackup_Yes                         7010 non-null   uint8
18  DeviceProtection_No internet service      7010 non-null   uint8
19  DeviceProtection_Yes                     7010 non-null   uint8
20  TechSupport_No internet service           7010 non-null   uint8
21  TechSupport_Yes                          7010 non-null   uint8
22  StreamingTV_No internet service           7010 non-null   uint8
23  StreamingTV_Yes                          7010 non-null   uint8
24  StreamingMovies_No internet service       7010 non-null   uint8
25  StreamingMovies_Yes                      7010 non-null   uint8
26  Contract_One year                        7010 non-null   uint8
27  Contract_Two year                        7010 non-null   uint8
28  PaymentMethod_Credit card (automatic)    7010 non-null   uint8
29  PaymentMethod_Electronic check           7010 non-null   uint8
30  PaymentMethod_Mailed check               7010 non-null   uint8
dtypes: float64(2), int64(7), object(1), uint8(21)
memory usage: 746.2+ KB
```


Dilakukan juga penambahan fitur/variabel yang merupakan gabungan antara "PhoneService", "MultipleLines_Yes", "OnlineSecurity_Yes", "OnlineBackup_Yes", "DeviceProtection_Yes", "TechSupport_Yes", "StreamingTV_Yes", "StreamingMovies_Yes" bernama NumServices untuk mempermudah kita dalam melihat jumlah total service yang digunakan.

NumServices
1
3
3
3
1
...
7
6
1
2
6

Modeling

Dataset hasil feature engineering (df_fe) kemudian dipisahkan menjadi fitur prediktor (X) dan variabel target (y), dengan Churn sebagai target. Proses pembagian data dilakukan menggunakan train-test split 80:20 serta stratified sampling, sehingga proporsi pelanggan churn dan tidak churn pada data latih dan data uji tetap seimbang. Pendekatan ini penting untuk menghindari bias evaluasi, terutama karena kasus churn umumnya bersifat tidak seimbang.

```
Model: Logistic Regression
Recall : 0.5390835579514824
ROC AUC: 0.84726053003783
```

```
Model: Decision Tree
Recall : 0.477088948787062
ROC AUC: 0.6448153076723983
```

```
Model: Random Forest
Recall : 0.4797843665768194
ROC AUC: 0.8178579925281241
```

Pada tahap awal pemodelan, tiga algoritma dibandingkan, yaitu Logistic Regression, Decision Tree, dan Random Forest dengan seluruh variabel prediktor intact. Evaluasi model dilakukan menggunakan Recall dan ROC-AUC, dengan fokus utama pada recall karena tujuan bisnis adalah meminimalkan pelanggan churn yang tidak terdeteksi. Hasil menunjukkan bahwa Logistic Regression menghasilkan recall tertinggi (0.539) dan ROC-AUC sebesar 0.847, yang menandakan kemampuan diskriminasi yang baik antara pelanggan churn dan non-churn.

Random Forest menunjukkan performa yang kompetitif dengan ROC-AUC 0.817, namun recall yang lebih rendah dibanding Logistic Regression. Sementara itu, Decision Tree menunjukkan performa paling rendah pada kedua metrik, mengindikasikan kecenderungan overfitting dan generalisasi yang kurang baik.

```
RandomizedSearchCV(cv=5, estimator=RandomForestClassifier(random_state=42),
                  n_iter=20, n_jobs=-1,
                  param_distributions={'max_depth': [None, 5, 10, 20],
                                      'max_features': ['sqrt', 'log2'],
                                      'min_samples_leaf': [1, 2, 5],
                                      'min_samples_split': [2, 5, 10],
                                      'n_estimators': [100, 200, 300]},
                  random_state=42, scoring='recall')
```

Random Forest kemudian dioptimalkan menggunakan RandomizedSearchCV dengan fokus pada Recall sebagai metrik utama. Beberapa parameter penting seperti n_estimators, max_depth, dan min_samples_leaf diuji untuk meningkatkan kemampuan model dalam menangkap pola churn.

```
Random Forest (Tuned)
Recall : 0.48787061994609165
ROC AUC: 0.8216253029403844
```

Hyperparameter tuning ini terbukti telah meningkatkan performa ROC AUC daripada model random forest, naik hingga 0.821 akan tetapi masih kalah dengan performa overall dari Logistic Regression. Selanjutnya kembali dilakukan pemodelan ulang dengan menggunakan fitur NumService sebagai representasi dari fitur services. Untuk dibandingkan performanya.

```
Model: Logistic Regression
Recall : 0.5040431266846361
ROC AUC: 0.8348657912005458
```

```
Model: Decision Tree
Recall : 0.477088948787062
ROC AUC: 0.647604842863156
```


```
Model: Random Forest
Recall : 0.4716981132075472
ROC AUC: 0.8122017981652335
```

Didapati bahwa performa regresi logistik dan random forest secara overall menurun, dan hanya decision tree yang sedikit membaik dengan urutan peringkat yang sama, yakni logistic regression > decision tree > random forest. Selanjutnya dilakukan hyperparameter tuning untuk random forest dan didapat hasil sebagai berikut

```
RandomizedSearchCV(cv=5, estimator=RandomForestClassifier(random_state=42),
                  n_iter=20, n_jobs=-1,
                  param_distributions={'max_depth': [None, 5, 10, 20],
                                      'max_features': ['sqrt', 'log2'],
                                      'min_samples_leaf': [1, 2, 5],
                                      'min_samples_split': [2, 5, 10],
                                      'n_estimators': [100, 200, 300]},
                  random_state=42, scoring='recall')
```

```
Random Forest (Tuned)
Recall : 0.5067385444743935
ROC AUC: 0.835254025479672
```


Sehingga didapat bahwa model memiliki evaluasi metrik yang lebih baik dengan recall 0.507 dan ROC AUC 0.835, lebih baik daripada model logistic regression dengan variabel number of services.



Berikut adalah top 20 fitur terpenting pada model terbaik random forest dengan tuning. Berdasarkan hasil feature importance dari model Random Forest, tenure merupakan fitur paling dominan dalam memprediksi churn pelanggan. Hal ini menunjukkan bahwa lama pelanggan berlangganan memiliki pengaruh terbesar terhadap kemungkinan churn, di mana pelanggan dengan masa berlangganan yang lebih pendek cenderung memiliki risiko churn yang lebih tinggi. Selanjutnya, TotalCharges dan MonthlyCharges juga memiliki kontribusi yang sangat signifikan, mengindikasikan bahwa faktor finansial—baik akumulasi biaya maupun beban biaya bulanan—berperan penting dalam keputusan pelanggan untuk berhenti berlangganan.

Fitur InternetService_Fiber optic muncul sebagai salah satu variabel kategorikal paling berpengaruh, yang mengindikasikan bahwa jenis layanan internet tertentu memiliki pola churn yang berbeda, kemungkinan terkait dengan ekspektasi kualitas layanan dan harga. Selain itu, PaymentMethod_Electronic check juga menunjukkan tingkat kepentingan yang cukup tinggi, yang mengisyaratkan bahwa metode pembayaran tertentu berasosiasi dengan perilaku churn yang lebih tinggi.

Variabel kontrak seperti `Contract_Two year` dan `Contract_One year` memiliki pengaruh yang cukup besar dan bersifat protektif terhadap churn, menegaskan bahwa pelanggan dengan kontrak jangka panjang cenderung lebih loyal dibandingkan pelanggan dengan kontrak bulanan. Fitur hasil feature engineering yaitu `NumServices` juga masuk dalam sepuluh besar, yang menunjukkan bahwa semakin banyak layanan yang digunakan pelanggan, semakin kecil kemungkinan pelanggan untuk churn. Sementara itu, variabel demografis seperti `SeniorCitizen`, `gender`, dan `Partner` memiliki kontribusi relatif kecil, menandakan bahwa faktor perilaku dan layanan jauh lebih penting dibandingkan karakteristik personal dalam memprediksi churn.



Summary

Best Model untuk random forest adalah Random Forest dengan prediktor tanpa variabel dengan indikasi multikolinearitas dan beberapa diwakilkan oleh fitur yang di feature engineering (`numservices`) dan tuned sehingga Recall improve menjadi 50.67% dan ROC AUC 83.52%. Sedangkan untuk logistic regression best model adalah dengan seluruh prediktor dengan Recall 53.9% dan AUC 84.7%. Akan tetapi model Random Forest yang telah dituning dipilih sebagai model akhir karena lebih robust terhadap hubungan non-linear antar fitur dan lebih stabil terhadap perubahan data.

Beberapa fitur terpenting adalah `tenure` dengan lebih dari 0.200 importance score, dilanjutkan dengan `total charges`, `monthly charges`, `internet service`, `payment method`, `contract`, `number of services`, dan lainnya.

Rekomendasi Bisnis:

- Fokus Retensi Pelanggan Baru

Karena `tenure` adalah faktor paling dominan, perusahaan sebaiknya memprioritaskan program retensi pada pelanggan dengan masa berlangganan awal (misalnya < 6 atau 12 bulan). Strategi yang dapat dilakukan antara lain program *welcome retention*, diskon khusus pelanggan baru, atau Follow-up proaktif dalam 1–3 bulan pertama

- Optimasi Struktur Harga dan Nilai Layanan

Tingginya pengaruh MonthlyCharges dan TotalCharges menunjukkan bahwa pelanggan sensitif terhadap biaya. Oleh karena itu evaluasi kembali harga untuk pelanggan dengan biaya bulanan tinggi, pastikan harga sebanding dengan kualitas layanan dan berikan penawaran personalisasi bagi pelanggan dengan tagihan tinggi

- Dorong Bundling dan Cross-Selling Layanan

Karena NumServices berpengaruh cukup besar maka dorong pelanggan untuk menggunakan lebih dari satu layanan, tawarkan paket bundling (misalnyaa internet + security + streaming), berikan potongan biaya untuk pelanggan multi-layanan sebagai promosi. Hal ini karena pelanggan dengan banyak layanan cenderung lebih “terikat” dan sulit berpindah.